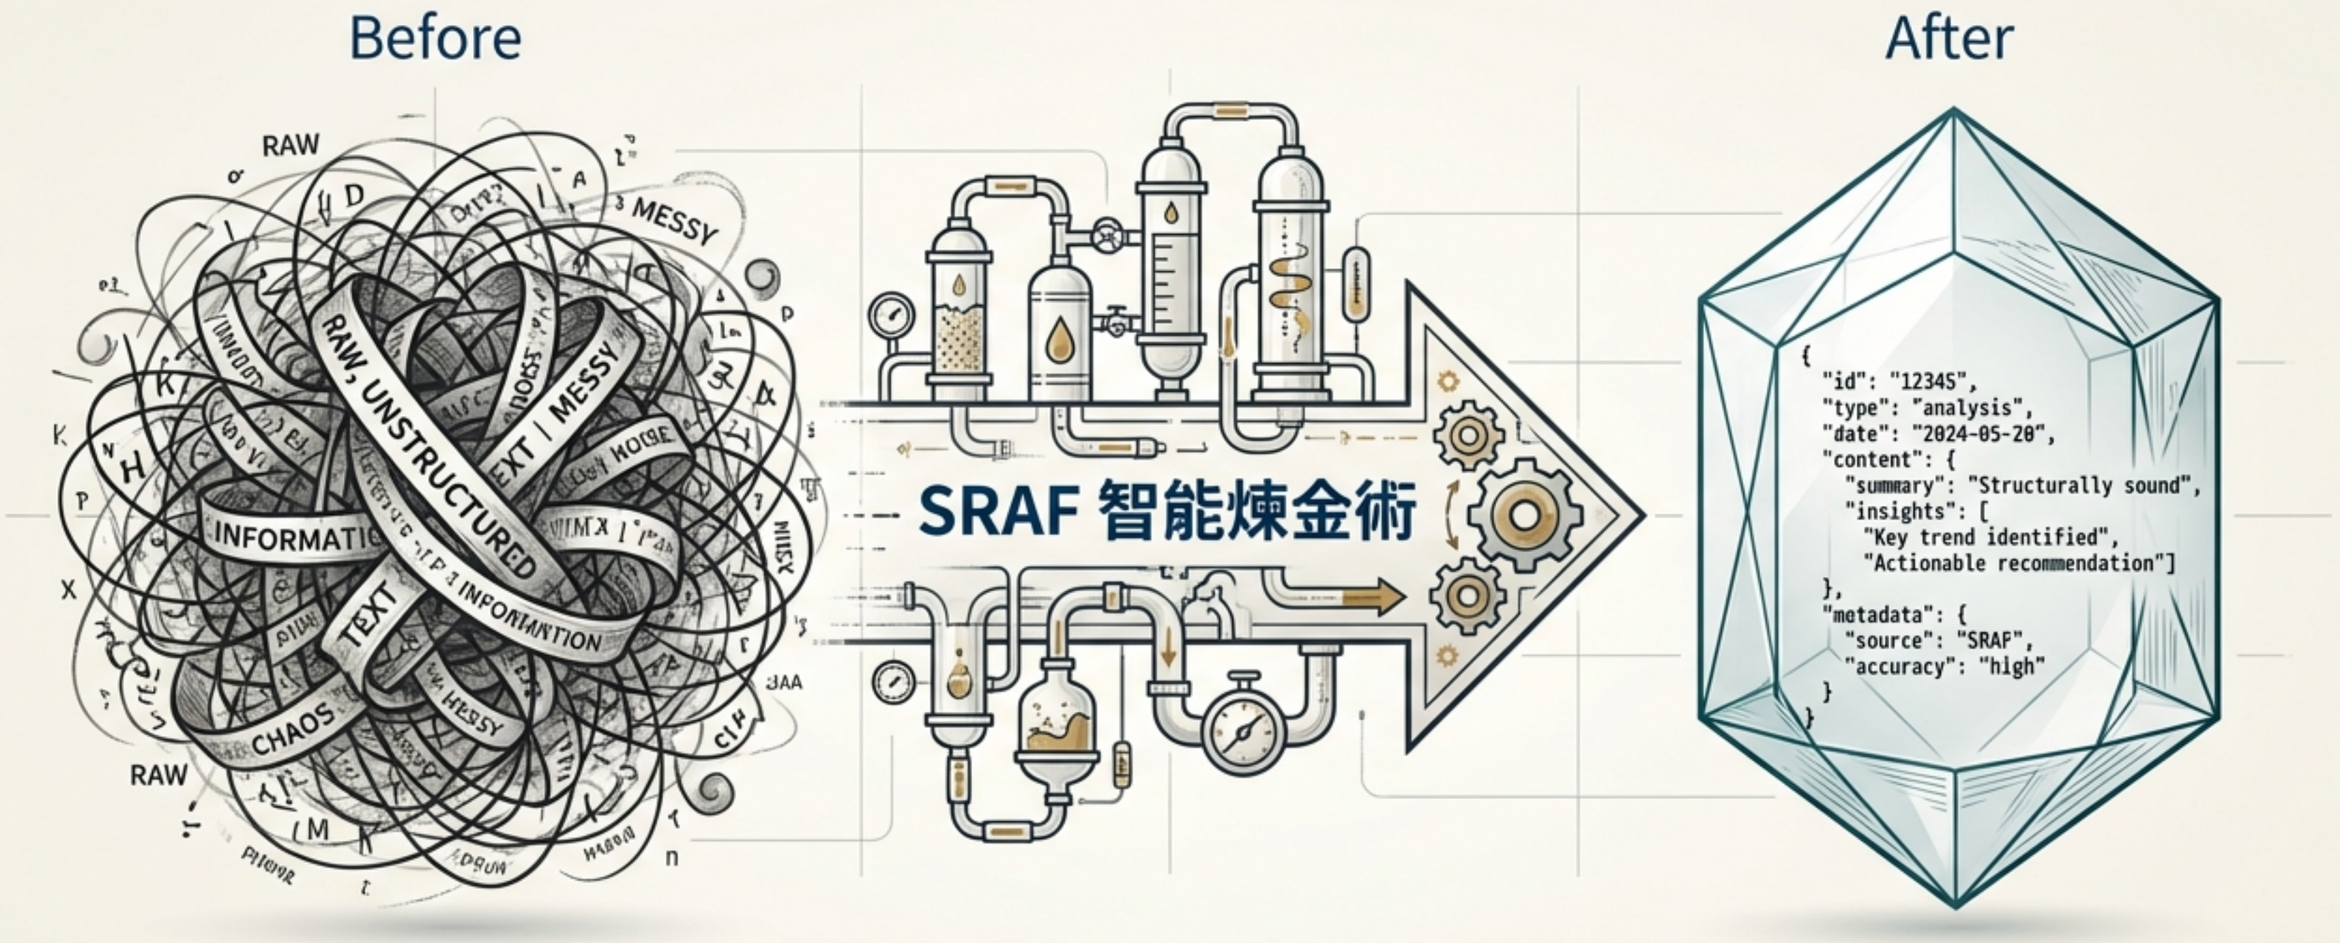
SRAF: 結構化檢索代理框架

Structured Retrieval Agent Framework

駕馭大型語言模型，實現精準數據萃取

NotebookLM

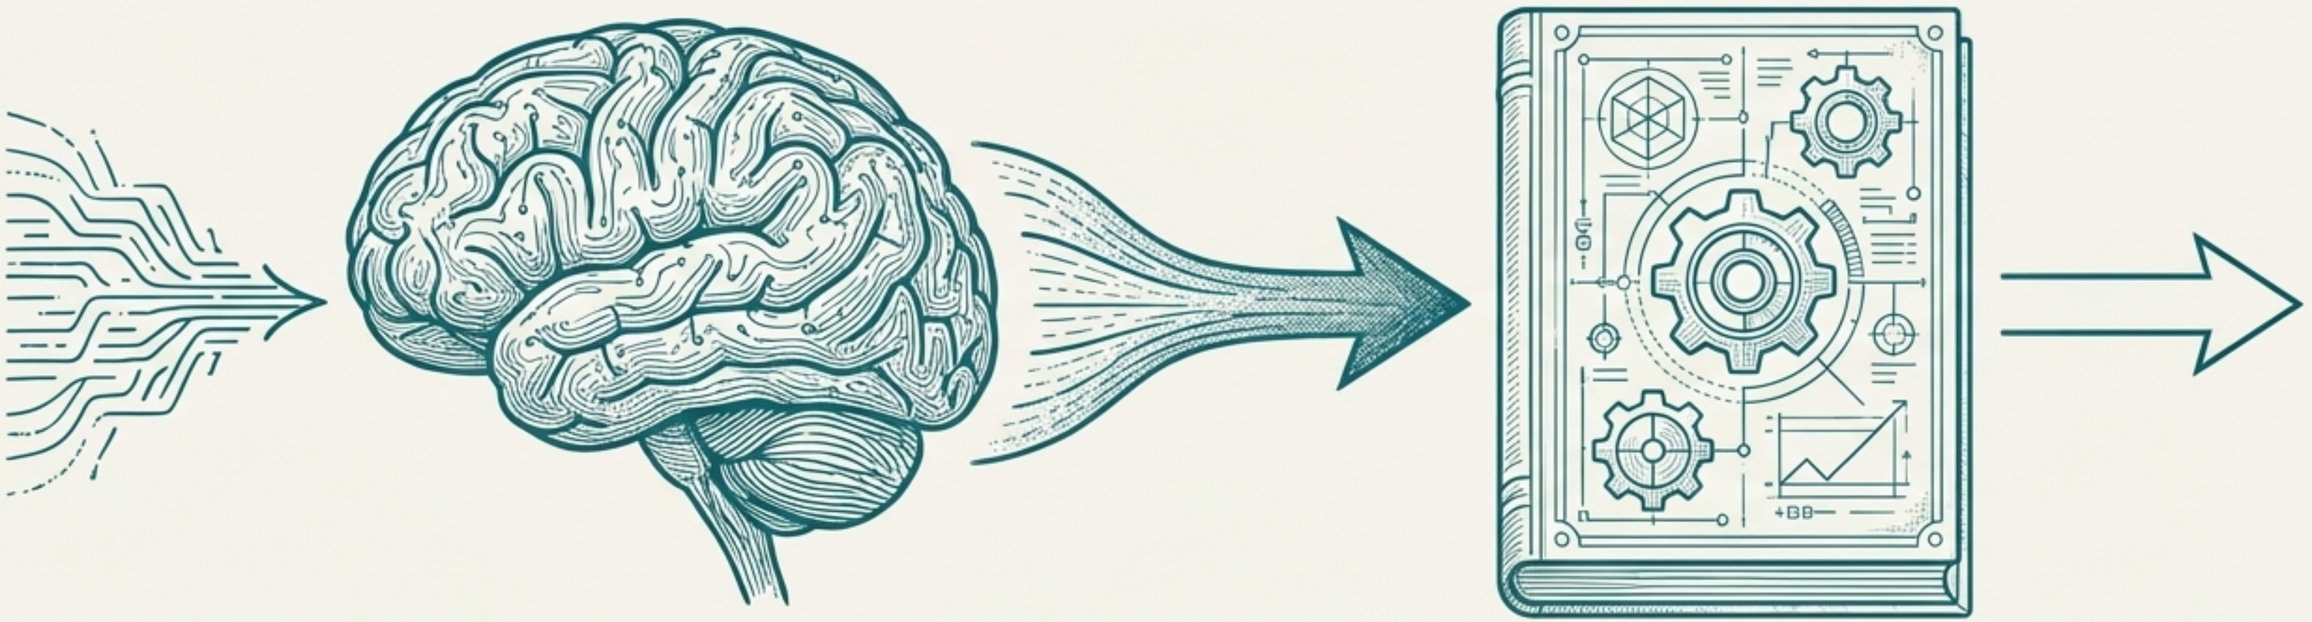
從雜亂無章到洞察分析：SRAF 的核心使命



SRAF 的使命是將複雜、特定領域的非結構化文本，以無與倫比的準確性與可控性，自動化轉換為可供分析的結構化數據。

NotebookLM

雙引擎架構：結合語言模型的彈性與規則框架的剛性



大型語言模型 (LLM)

語義理解與生成引擎

SRAF 規則框架

精準性與一致性的保障

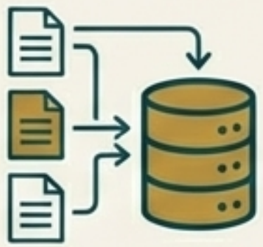
SRAF 不僅僅是呼叫 LLM API。我們打造了一個完整的控制框架，確保每一次的輸出都符合嚴格的品質標準。

NotebookLM

萬變不離其宗：通用提取規則 `MULTIDIM_EXTRACTION_Rule`



Rule 1
輸出格式必須為扁平化、SQL-friendly 的 JSON。



Rationale
確保與資料庫和數據倉儲的直接兼容性，簡化後續分析流程。



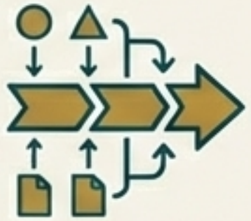
Rule 2
關鍵欄位如 `title`（標題）和 `date`（日期）不得為空值或 "unknown"。



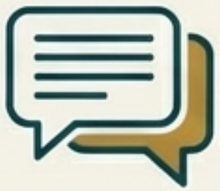
Rationale
維護核心元數據的完整性，杜絕無效記錄。



Rule 3
JSON 中的所有值都必須是有效且非空的字串。



Rationale
從源頭防止數據品質問題向下游擴散。



Rule 4
`event`（事件）欄位的值必須簡潔扼要。



Rationale
提升摘要內容的可讀性與實用價值。

NotebookLM

動態指令生成：將規則轉化為精確的 LLM Prompt

第一步：注入通用規則
系統會自動將
MULTIDIM_EXTRACTION_Rule`
作為指令的基礎。

```
# SRAF Programmatically Constructs the Prompt
prompt = f"{MULTIDIM_EXTRACTION_Rule}" + {
  "article_title": "{removeStrSuffix(MainFileName, '_tika')}",
  "input_text": "{content}"
}
# LLM_call(prompt)
```

第二步：智能生成元數據
透過 `removeStrSuffix`
等輔助函式，從檔名等來源
資源中提取
取 `article_title`，豐
富輸入內容。

第三步：結合原始文本
將待處理的文本內容
（content`）放入指
定定欄位，形成完整
整的提取任務。

NotebookLM

深度解析：日期與時間判讀 (一) - 基礎規則與防錯機制

Challenge 1: Non-Standard Formats

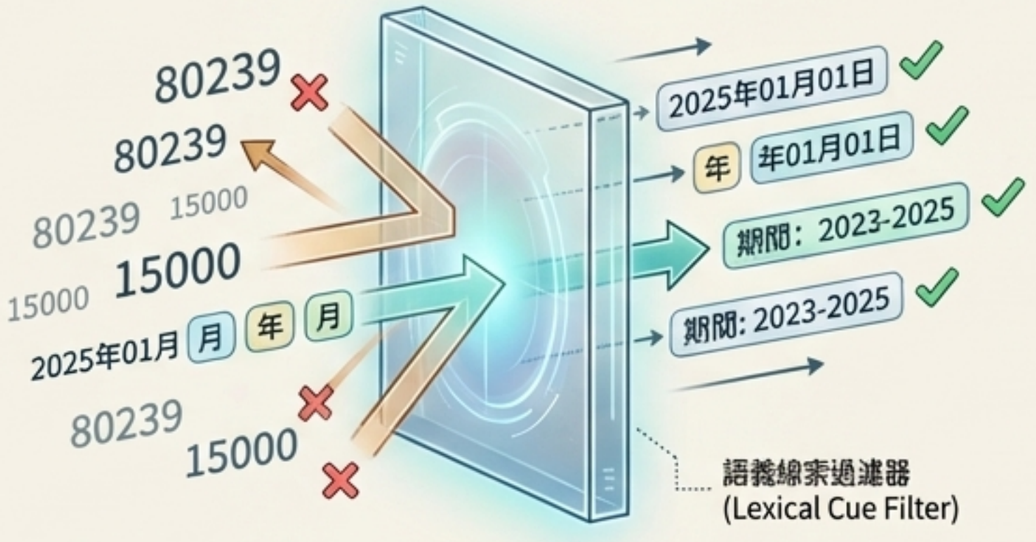


文本中的日期格式不一，例如「民國年」。

SRAF Solution: 建立「民國年轉換」規則。(`民國 114 年 01 月 01 日` → `2025-01-01`)

Rationale: 將所有日期標準化為西元格式，確保時間序列分析的準確性。

Challenge 2: Differentiating Dates from Numbers



純數字（如 20250101）可能被誤判為日期。

SRAF Solution: 建立「語義線索」判斷規則。僅當文本中出現明確的日期相關語詞時，才將內容視為日期。

Required Cues:

- 包含 `年/月/日` 字樣
- 包含 `期間`、`起`、`迄`、`某日`、`當月`、`本年` 等詞彙

Rationale: 大幅降低「幻覺」日期出現的機率，從根本上避免錯誤提取。

NotebookLM

終極挑戰：破解四位數「0830」的歧義

判斷為「時間」(HHmm) 的條件

- 若鄰近 (約 10-15 字) 出現**時間語氣詞**：
  時, 時許, 上午, 下午, 凌晨, 晚間
- 若上下文場景與**時間高度相關**：
  偵獲, 觀測, 升空, 通報, 航跡, 雷達

判斷為「日期」(MMDD) 的條件

若鄰近出現**日期語氣詞**，且同一句話中已存在另一個**完整的明確日期**，才可視為日期。



SRAF 倚賴上下文證據進行確定性判斷，而非機率猜測。

NotebookLM

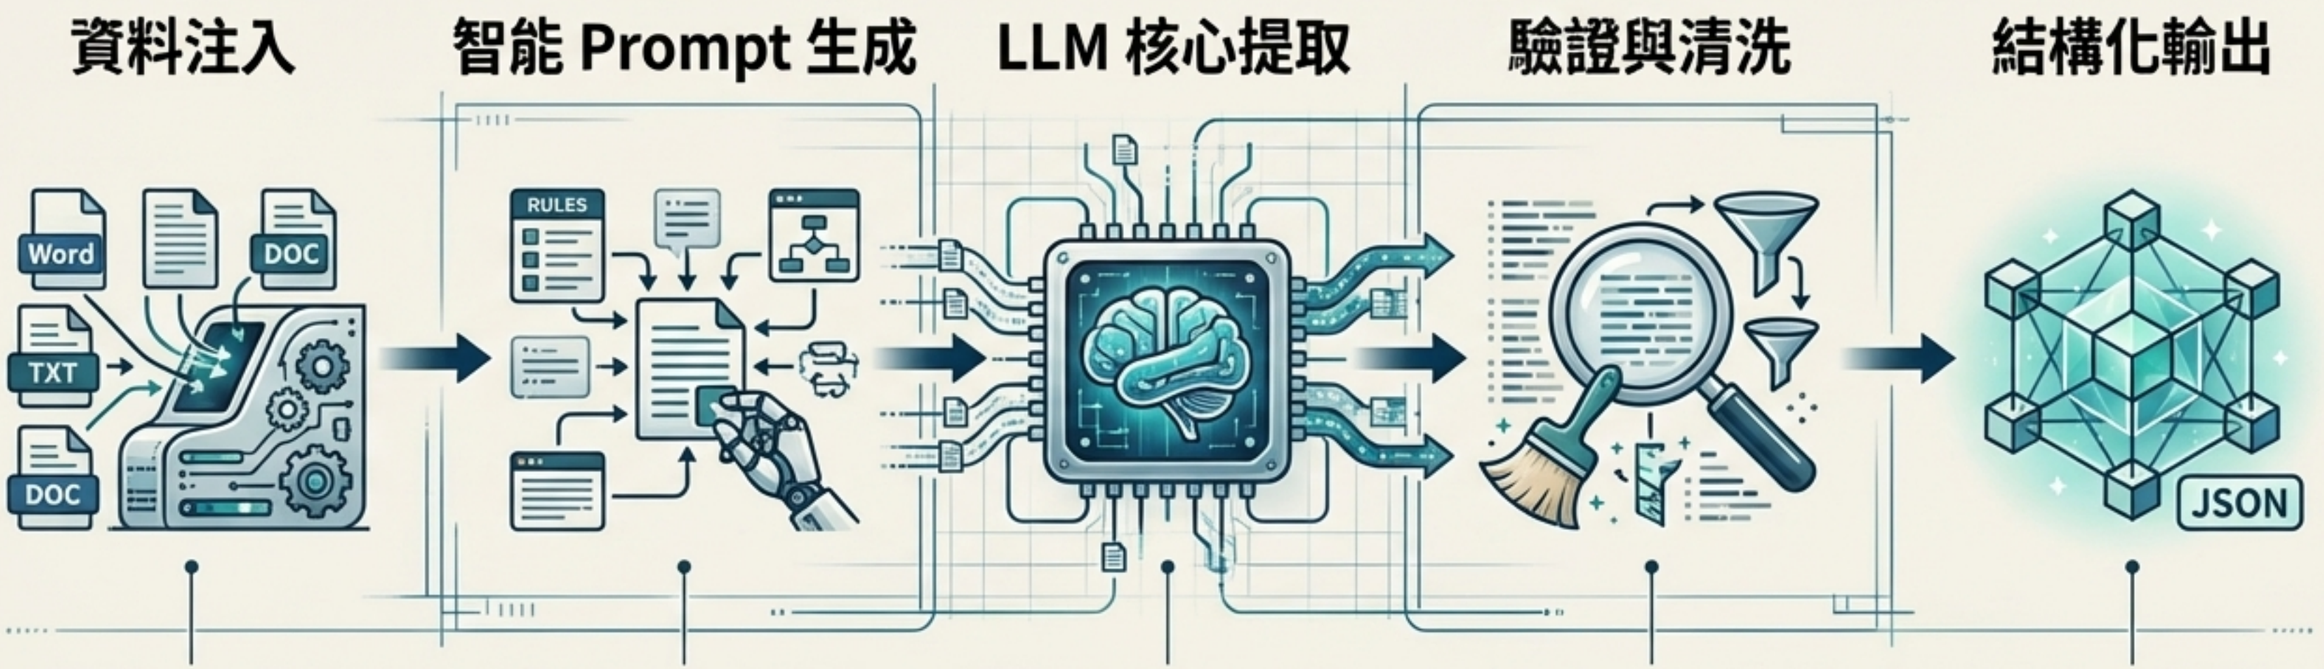
防禦前線：前處理與過濾器機制



- **過濾無關內容：**
  自動排除過短、可能不含有效資訊的文件。
- **提升處理效率：**
  確保 LLM 的運算資源集中在最具價值的內容上。
- **成本控管：**
  避免對大量無關文件進行不必要的 API 呼叫。

NotebookLM

SRAF 運作全流程：從原始文件到結構化產出



接收原始文件(如：Word, Txt 檔)。

根據內容動態建構指令。

呼叫大型語言模型執行提取。

交叉檢查並格式化 LLM 輸出。

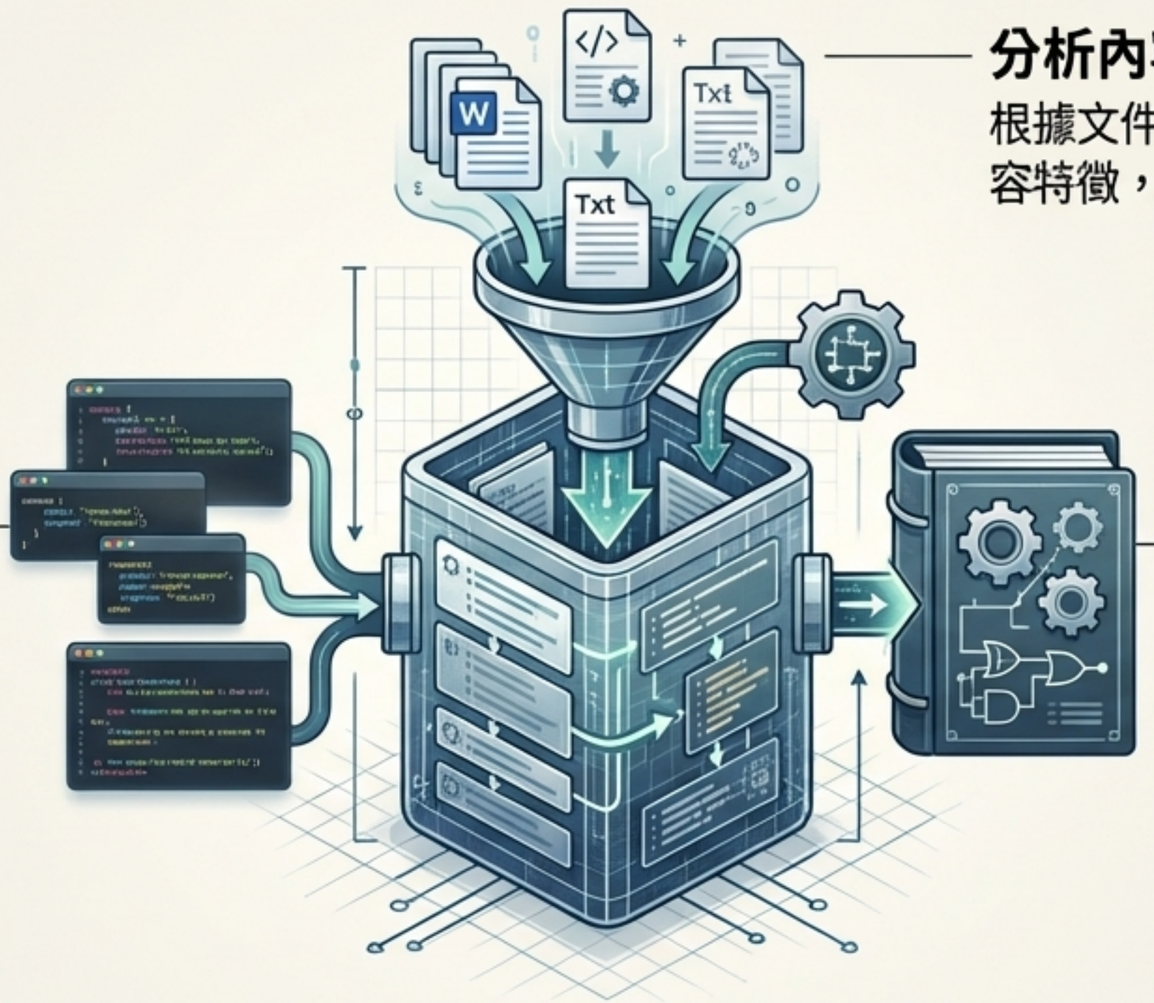
產出標準化的 JSON 資料。

NotebookLM

流程解析 (一)：我們的 Prompt並非一成不變

分析內容與選擇範本

根據文件類型（如 Word vs. Txt）和內容特徵，選擇最合適的基礎指令範本。



注入 Few-Shot 範例

參照過去的成功案例，動態加入 1-2 個高品質的範例，為 LLM 提供清晰的輸出指引。

嵌入 SRAF 核心規則

將 `MULTIDIM_EXTRACTION_Rule` 及相關的情境判斷規則編程方式注入 Prompt。

SRAF 的 Prompt 是為每一份文件量身打造的動態指令集，而非靜態模板。

NotebookLM

流程解析（二）：我們信任，但我們驗證

第一層：數據清洗 (Layer 1: Data Cleansing)



動作：自動執行標準化清理程序，如去除多餘的空白、修正輕微的格式錯誤。
目標：確保數據的純淨與一致性。

第二層：規則驗證 (Layer 2: Rule-Based Verification)



動作：使用正規表示式 (RegEx)、關鍵字匹配、以及呼叫專門的「驗證代理 (Verification Agents)」對 LLM 的輸出進行二次檢查。
目標：捕捉並修正任何不符合 SRAF 核心規則的潛在錯誤。

LLM 的輸出只是第一步草稿，SRAF 的驗證流程才是最終品質的保證。

NotebookLM

效果展示：化繁為簡，一目了然

處理前 - Before Processing

"附件1_國家安全簡報_陳情函.txt"
"附件2_雷達偵獲報告_20240830.txt"

SRAF 處理後 - After SRAF Processing


```
{
  "article_title": "雷達偵獲報告_20240830",
  "date": "2024-08-30",
  "time": "08:30",
  "event": "偵獲不明航跡，於上午八時三十分通報。",
  "location": "台灣西南空域"
}
```


NotebookLM

SRAF 的核心優勢



精準 (Precision)

基於規則的啟發式判斷斷，克服了 LLM 的模糊性與不確定性，尤其在處理日期、時間等關鍵資訊時。



可控 (Control)

結構化的框架確保了輸出結果的可靠性與一致性，讓 AI 的產出不再是無法預測的「黑盒子」。



效率 (Efficiency)

將繁瑣、高度依賴人力的複雜提取任務自動化，釋放專家資源，專注於更高價值的分析與決策。

NotebookLM

Q&A

感謝聆聽

NotebookLM